数据采集与集成技术　大作业要求（2026 秋）

一、题目

自选。结合个人兴趣和专业方向，围绕数据采集与集成，设计并实现一个完整的智能数据系统。鼓励使用大模型、智能体、多模态等新技术。

二、项目范围

自选主题可包括但不限于：

1. 网站数据采集与分析（招聘、电商、新闻、舆情等）
2. 物联网/传感器数据采集与可视化
3. 日志数据采集与智能分析
4. 多模态数据采集（图文/音视频）与知识库构建
5. 基于 RAG 的智能问答系统
6. Agent 自动化数据采集系统

要求解决一个真实问题：学习、生产、生活中的信息获取与分析需求。

三、内容要求

综合课程全部实验内容，完成一个端到端系统。必须包含以下三个基本部分：

1. 数据采集：从 Web、API、物联网、日志等来源获取数据
2. 数据集成/处理：清洗、结构化、向量化或融合
3. 数据展示/应用：可视化、问答、报表或智能服务

鼓励（不强制）使用以下新技术，作为加分项：

1. LLM 辅助抽取或清洗（实验 4 方法）
2. Agent 自动化采集（实验 3 阶段 B 方法）
3. 向量知识库与 RAG 问答（实验 5 方法）
4. 多模态数据处理

5. 合成数据增强

四、开发形式

1. 1-2 人一组，必须分工明确
2. 鼓励自主学习新技术，不局限于课堂内容
3. 参考示例可以，但必须有自己的创新，禁止直接抄袭

五、提交内容

1. 项目设计报告

包括但不限于：

1. 封面与目录
2. 项目背景与问题定义
3. 需求分析
4. 整体架构设计（含系统架构图）
5. 详细设计：数据采集方案、数据处理流程、应用层实现
6. 关键技术实现：重点说明采集方法、AI 技术使用方式
7. 测试结果与数据展示
8. 小组分工
9. 心得体会：课程收获、对数据采集领域的认识、课程建议

2. 项目电子档

1. 项目设计报告（电子版）
2. 答辩 PPT（申优组必须）
3. 源代码
4. 数据库文件或数据集
5. 使用说明（如何运行）
6. 联系方式（邮箱必交）

六、提交方式与时间

1. Canvas 提交，文件打包为"学号+姓名.rar"
2. 无需纸质版
3. 提交时间：第 16 周

八、答辩与申优

申优组需答辩，准备 PPT 和演示环境，答辩 5 分钟。安排在 16-17 周课堂或周末。非申优组无需答辩。

九、考核标准

1. 系统完成情况（50%）

1. 需求满足度
2. 完整性与工作量
3. 技术难度与新技术使用
4. 系统可运行性

2. 报告撰写（30%）

1. 内容完整性
2. 技术描述清晰度
3. 报告规范

3. 答辩与展示（20%，申优组）

1. 演示流畅度
2. 问题回答
3. 创新点

十、温馨提示

1. 大作业 1-2 人一组，实验每人必做
2. 严禁抄袭，必须有自己的核心工作

3. 数据采集须遵守法律法规和 robots 协议